Clasificación de Estudios MRI Cerebrales mediante Redes Neuronales Convolucionales para la Detección de Tipos de Tumor

Otto Wilmer Castillo Santacruz, Edgar Andrés Pérez Mora y Silvio Yopasa Romero
Maestría en Inteligencia Artificial (MAIA), Universidad de los Andes, Bogotá, Colombia
{o.castillos, ea.perezm1, s.yopasa}@uniandes.edu.co

I. Introducción

La resonancia magnética cerebral (*Magnetic Resonance Imaging*, MRI) es la modalidad de referencia para la detección no invasiva, caracterización morfológica y planificación terapéutica de neoplasias intracraneales [1]. En la práctica clínica, la interpretación visual de múltiples cortes anatómicos exige alta especialización radiológica y presenta variabilidad, por lo que las redes neuronales convolucionales (CNN) son clave en el apoyo diagnóstico al extraer jerarquías espaciales directamente de cortes bidimensionales (2D), apoyando el diagnóstico asistido por computador [2].

El problema específico abordado es la clasificación supervisada multiclase de cortes 2D de MRI cerebral en $C = 4$ categorías: *glioma*, *meningioma*, tejido sin lesión (*healthy*) y adenoma hipofisario (*pituitary*). Aunque operar en 2D evita el costo volumétrico 3D, en el estado del arte diversos estudios basados en CNN y transferencia de aprendizaje [2] evalúan colecciones públicas sin auditar duplicados exactos entre particiones ni corregir marcos periféricos o sesgos de resolución, induciendo aprendizaje por atajos (*shortcut learning*) que sobreestima la generalización clínica [3].

El objetivo de este trabajo es diseñar, justificar y validar un metodo reproducible basado en CNN desde cero en PyTorch que maximice la exactitud diagnóstica en las cuatro categorías previniendo la fuga de datos y los atajos espurios. El enfoque integra: (i) deduplicación exacta por hash MD5; (ii) recorte anatómico (`CropToContent`) y relleno simétrico (`PadToSquare`); (iii) selección sistemática entre cuatro arquitecturas sobre una muestra estratificada del $30\,\%$ de entrenamiento; y (iv) la arquitectura propuesta `DoubleConvMRICNN` (1.24M parámetros), con bloques de doble convolución 3×3 [4] y agrupación global dual (*Avg+Max*), que alcanza una exactitud de $98.79\,\%$ y un *Macro F1-Score* de $98.75\,\%$ en prueba ($n = 990$).

II. Metodología

Visión general del enfoque. El flujo comprende cuatro etapas: auditoría y deduplicación por hash MD5, estandarización geométrica con caché en RAM (`CachedMRIDataset`), búsqueda de arquitecturas e hiperparámetros sobre el $30\,\%$ de entrenamiento sin tocar validación ni prueba, y entrenamiento final de la arquitectura seleccionado sobre el $100\,\%$ de entrenamiento con evaluación cuantitativa y cualitativa en prueba.

Datos y preprocesamiento. El conjunto público inicial contiene $7\,023$ imágenes 2D de MRI en escala de grises almacenadas en tres canales RGB. Mediante el hash MD5 se detectaron 300 grupos idénticos equivalentes a 426 copias redundantes (*healthy*: 294, *meningioma*: 114, *pituitary*: 17, *glioma*: 1), sin contradicciones de etiqueta. Al conservar una copia por grupo, el conjunto depurado consta de $N = 6\,597$ imágenes únicas balanceadas (razón 1.14): *pituitary* ($1\,740$; $26.38\,\%$), *healthy* ($1\,706$; $25.86\,\%$), *glioma* ($1\,620$; $24.56\,\%$) y *meningioma* ($1\,531$; $23.21\,\%$).

El análisis exploratorio identificó 387 resoluciones (150–$1\,920$ px) y dos sesgos en *healthy*: menor resolución mediana (228×242 px vs. 512×512 px en $> 90\,\%$ de las clases tumorales) y marcos claros periféricos en el $14.30\,\%$ de sus muestras ($2.81\,\%$ en cuatro lados). Para mitigar atajos espurios [3], se aplican dos transformaciones deterministas:

(1) `CropToContent`, que recorta bandas brillantes periféricas al cuadro delimitador del tejido (intensidad $>$ 20 en $\geq$ $2\,\%$ de la fila o columna, margen de 4 px); y (2) `PadToSquare`, que aplica relleno simétrico con ceros hasta formato cuadrado antes de interpolar a 224×224 px y normalizar con estadísticos de ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$). El conjunto depurado se dividió estratificadamente (semilla 42) en `Train` ($70\,\%$, $4\,617$), `Val` ($15\,\%$, 990) y `Test` ($15\,\%$, 990), con disyunción estricta de hashes MD5. Solo en `Train` se aplicó aumento estocástico: volteo horizontal ($p = 0.5$), rotación afín ($\pm 10°$), traslación ($\pm 5\,\%$), brillo/contraste ($\pm 15\,\%$) y desenfoque gaussiano ($k = 3, p = 0.3$).

Arquitecturas candidatas y modelo propuesto. Sobre un subconjunto estratificado de `Train` ($30\,\%$: `Sub-Train` 969, `Sub-Val` 208, `Sub-Test` 208; 15 épocas) se evaluaron cuatro redes: (1) **Arq. 1 (`BaselineCNN + Plateau`):** 4 bloques simples ($3 \to 32 \to 64 \to 128 \to 256$) con `Conv2d(3 × 3)`, `BatchNorm2d`, `ReLU` y `MaxPool2d(2,2)` ($224 \to 14$), `AdaptiveAvgPool2d(1,1)` y cabezal denso ($256 \to 128 \to 4$, `Dropout` $p = 0.4$; $422\,308$ parámetros) con `ReduceLROnPlateau` ($\eta = 10^{-3}$); (2) **Arq. 2 (`BaselineCNN + CosineLR + Smooth`):** misma red con `CosineAnnealingLR` ($\eta = 8 \times 10^{-4} \to 10^{-5}$), suavizado de etiquetas ($\varepsilon = 0.05$) [5] y recorte de gradiente ($\|\nabla\|_2 \leq 2.0$); (3) **Arq. 3 (`Deep5BlockCNN`):** 5 bloques simples hasta 512 canales ($224 \to 7$), agrupación dual (`Avg+Max`) y cabezal $1\,024 \to 256 \to 4$ con

`BatchNorm1d` y `Dropout` ($p = 0.3$; 1 833 252 parámetros); y (4) **Arq. 4 (`DoubleConvMRICNN`, ganadora):** mantiene 4 niveles espaciales ($224 \rightarrow 14$), pero sustituye cada bloque simple por **dos convoluciones** 3×3 **consecutivas** (`Conv2d-BN-ReLU-Conv2d-BN-ReLU-MaxPool2d`), logrando un campo receptivo efectivo de 5×5 con doble no-linealidad por etapa [4], seguido de agrupación dual (`AvgPool+MaxPool`, 512 canales) y clasificador denso ($512 \rightarrow 128 \rightarrow 4$) con `BatchNorm1d(128)`, `ReLU` y `Dropout` ($p = 0.3$; 1 239 524 parámetros).

Estrategia de entrenamiento y evaluación. El entrenamiento final de `DoubleConvMRICNN` se ejecutó por 25 épocas sobre `Train` ($B = 32$, semilla 42), con `AdamW` ($\eta = 6 \times 10^{-4}$, $\lambda = 10^{-4}$), `CosineAnnealingLR` ($T_{\max} = 25$, $\eta_{\min} = 10^{-5}$), recorte de gradiente ($\max_norm = 2.0$) y entropía cruzada ponderada ($w_c = N_{\text{train}}/(C \cdot n_c)$: $w_{\text{gli}} = 1.0179$, $w_{\text{men}} = 1.0777$, $w_{\text{hea}} = 0.9667$, $w_{\text{pit}} = 0.9477$) con $\varepsilon = 0.05$ en entrenamiento, restaurando el mejor modelo en validación y evaluando exactitud (*Accuracy*), precisión (*Precision*), sensibilidad (*Recall*) y *Macro F1-Score*.

III. Resultados

En la Tabla I, sustituir `ReduceLROnPlateau` por `CosineAnnealingLR` con suavizado y recorte de gradiente (Arq. 1 vs. Arq. 2) reduce la desviación estándar de la pérdida en validación de $\sigma_{\text{val}} = 0.437$ (pico 2.17) a $\sigma_{\text{val}} = 0.251$ (pico 1.27), elevando la exactitud en `Sub-Test` de 80.29 % a 85.10 %. `DoubleConvMRICNN` (Arq. 4) supera a todas las candidatas con 96.15 % de exactitud y 95.99 % de *Macro F1*, con 32.4 % menos parámetros que `Deep5BlockCNN` (1.24M vs. 1.83M).

TABLE I

Comparación de arquitecturas en exploración (Sub-Test, $n = 208$, 15 épocas).

Arquitectura	Parám.	Val Loss	σ_{val} (Pico)	Test Loss	Acc (%)	Macro F1	F1 Men./Gli.
1. `BaselineCNN` (Plateau)	422k	0.4972	0.437 (2.17)	0.4641	80.29	79.30	59.77 / 81.74
2. `BaselineCNN` (Cosine+Sm.)	422k	0.4672	0.251 (1.27)	0.4624	85.10	84.56	75.00 / 81.08
3. `Deep5BlockCNN` (5 bloq.)	1.83M	**0.1996**	0.400 (1.73)	**0.1566**	93.75	93.59	88.42 / 95.05
4. `DoubleConvMRICNN`	1.24M	0.2433	0.367 (1.51)	0.1684	**96.15**	**95.99**	**92.31 / 96.15**

Al entrenar sobre el 100 % de `Train` (25 épocas), `DoubleConvMRICNN` alcanzó su óptimo de validación en la **época 23** (`Val Loss`: 0.0746, `Val Acc`: 98.38 %, `Val Macro F1`: 98.34 %; `Train Loss`: 0.2338 acotada por $\varepsilon = 0.05$, `Train Acc`: 99.89 %). En el conjunto de prueba independiente (`Test`, $n = 990$, Tabla II), obtuvo **`Test Loss`:** 0.0716, **exactitud global de** 98.79 % (978/990 aciertos) y ***Macro F1-Score* de** 98.75 %.

TABLE II

Matriz de confusión (filas: real; columnas: predicción) y métricas en Test ($n = 990$).

Real \ Pred.	Gli.	Men.	Hea.	Pit.	Prec. (%)	Sens. (%)	F1 (%)
Glioma (243)	**241**	2	0	0	98.77	99.18	98.97
Meningioma (230)	3	**223**	3	1	97.81	96.96	97.38
Healthy (256)	0	2	**254**	0	98.83	99.22	99.03
Pituitary (261)	0	1	0	**260**	**99.62**	**99.62**	**99.62**
Promedio Macro / Exactitud Global (978/990)					**98.76**	**98.74**	**98.75 / 98.79**

La Fig. 1 muestra cuatro aciertos por clase (arriba) y cuatro errores en `Test` (abajo) con su confianza `softmax`. Los 12 errores totales **involucran a *meningioma*** (7 falsos negativos y 5 falsos positivos), con confianzas moderadas: *meningioma* $\rightarrow$ *glioma* (3 casos, media 62.27 %), *meningioma* $\rightarrow$ *healthy* (3 casos, 78.27 %), *glioma* $\rightarrow$ *meningioma* (2 casos, 53.48 %), *healthy* $\rightarrow$ *meningioma* (2 casos, 69.48 %), *meningioma* $\rightarrow$ *pituitary* (1 caso, 44.93 %) y *pituitary* $\rightarrow$ *meningioma* (1 caso, 78.55 %).

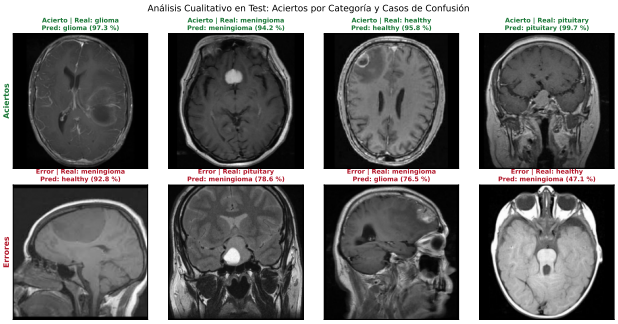


Fig. 1. Inspección cualitativa en `Test` ($n = 990$): aciertos (arriba) y errores de clasificación (abajo) con etiqueta real, predicción y confianza `softmax`.

IV. Discusión

Los resultados se explican por tres mecanismos: (i) **Capacidad representacional y campo receptivo:** distinguir un *glioma* infiltrativo de un *meningioma* extraaxial circunscrito exige integrar bordes locales y contexto global; apilar dos convoluciones 3×3 por bloque (`DoubleConvMRICNN`) genera un campo receptivo efectivo de 5×5 con doble no-linealidad antes de cada `MaxPool2d` [4], y concatenar `AvgPool+MaxPool` preserva tanto la activación máxima focal del tumor como la intensidad media del corte, elevando el F1 de *meningioma* de 59.77 % (`BaselineCNN`) a 92.31 % en `Sub-Test` y 97.38 % en `Test`, mientras *pituitary* (99.62 %), *healthy* (99.03 %) y *glioma* (98.97 %) superan el 98.9 %; (ii) **Estabilidad y calibración:** `CosineAnnealingLR`, suavizado ($\varepsilon = 0.05$) [5] y recorte de gradiente reducen la varianza de `BatchNorm2d` en validación y evitan sobreconfianza en los 12 cortes ambiguos de *meningioma* (44.9 %–78.6 %); y (iii) **Mitigación de *data leakage* y *shortcut learning*:** eliminar 426 duplicados MD5, recortar bordes con `CropToContent` y aplicar desenfoque gaussiano aseguran que *healthy* se clasifique por su parénquima y no por artefactos periféricos o de resolución [3]. Como limitaciones del conjunto público destacan la ausencia de identificadores DICOM por paciente (cortes contiguos de un mismo estudio volumétrico podrían coexistir entre particiones pese a eliminar duplicados exactos) y la mezcla no anotada de planos y secuencias (T1c, T2, FLAIR). Como trabajo futuro se propone aplicar mapas de atribución visual (*Grad-CAM*) sobre los 12 casos de confusión de *meningioma* y validar el modelo con partición agrupada por paciente.

References

[1] D. N. Louis *et al.*, "The 2021 WHO classification of tumors of the central nervous system: a summary," *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021.

[2] S. Deepak and P. M. Ameer, "Brain tumor classification using deep CNN features via transfer learning," *Comput. Biol. Med.*, vol. 111, p. 103345, 2019.
[3] R. Geirhos *et al.*, "Shortcut learning in deep neural networks," *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020.
[4] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Proc. ICLR*, 2015, pp. 1–14.
[5] C. Szegedy *et al.*, "Rethinking the Inception architecture for computer vision," in *Proc. IEEE CVPR*, 2016, pp. 2818–2826.