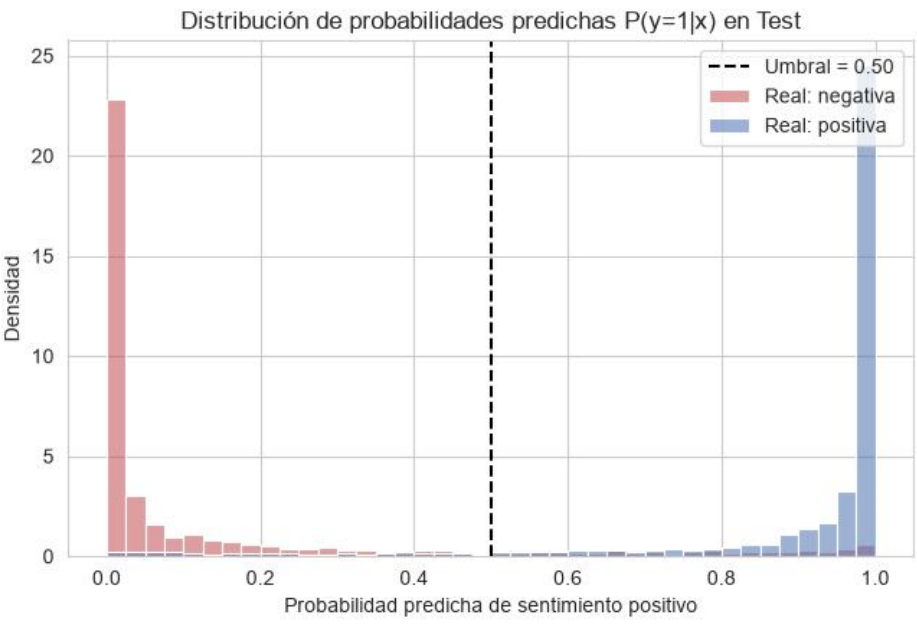
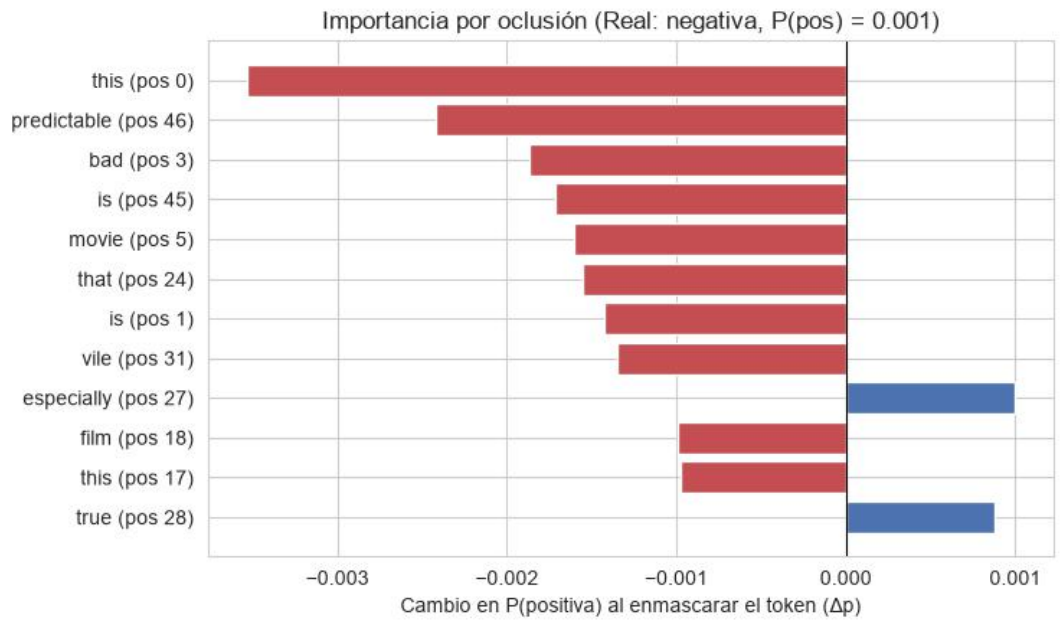

Distribución de probabilidades predichas P(y=1|x) en Test
Umbral = 0.50
Real: negativa
Real: positiva
Densidad
0
5
10
15
20
25
0.0
0.2
0.4
0.6
0.8
1.0
Probabilidad predicha de sentimiento positivo


Importancia por oclusión (Real: negativa, P(pos) = 0.001)
this (pos 0)
predictable (pos 46)
bad (pos 3)
is (pos 45)
movie (pos 5)
that (pos 24)
is (pos 1)
vile (pos 31)
especially (pos 27)
film (pos 18)
this (pos 17)
true (pos 28)
−0.003
−0.002
−0.001
0.000
0.001
Cambio en P(positiva) al enmascarar el token (Δp)