Clasificación de Sentimientos en Reseñas de Películas de IMDb mediante Redes Neuronales Recurrentes con Embeddings Preentrenados

Otto Wilmer Castillo Santacruz, Edgar Andrés Pérez Mora y Silvio Yopasa Romero
Maestría en Inteligencia Artificial (MAIA), Universidad de los Andes, Bogotá, Colombia
{o.castillos, ea.perezm1, s.yopasa}@uniandes.edu.co

I. Introducción

La clasificación binaria de sentimientos (positivo o negativo) en reseñas cinematográficas extensas es un problema fundamental del procesamiento de lenguaje natural [3], cuyo impacto radica en automatizar el filtrado masivo de opiniones no estructuradas para sistemas de recomendación en *streaming* y auditoría de audiencias, donde la revisión manual resulta inviable. Esta tarea es compleja porque la polaridad depende del orden secuencial, la negación contextual (p. ej., "*not good*") y los contrastes adversativos (p. ej., "*great cast, but terrible script*"), frente a los cuales las técnicas clásicas de bolsa de palabras fallan al descartar la estructura temporal.

En el aprendizaje profundo, este reto se aborda integrando vectores densos preentrenados (*embeddings*) como GloVe [4] con redes neuronales recurrentes (RNN). Mientras que las RNN simples sufren de desvanecimiento o explosión del gradiente en textos largos, celdas con compuertas como LSTM [1] y GRU [2] regulan el flujo de memoria reteniendo dependencias contextuales distantes. Asimismo, la agregación temporal dual (*Concat Mean-Max Pooling*) [5] rescata simultáneamente el tono global y los picos semánticos más representativos de la crítica.

El objetivo de este trabajo es diseñar, comparar y validar un método reproducible basado en RNN para clasificar la polaridad de las reseñas del corpus de IMDb [3] sin fuga de información. El enfoque propuesto integra: (i) depuración y deduplicación textual para suprimir ruido HTML y sesgos; (ii) codificación secuencial alineada con GloVe 6B [4] para transferir semántica léxica; (iii) evaluación multisemilla de cinco arquitecturas recurrentes en validación para cuantificar el efecto de las compuertas y del ajuste fino; y (iv) reentrenamiento y evaluación del modelo óptimo (GRU unidireccional con GloVe congelado, de solo 32 001 parámetros entrenables) con el propósito de maximizar la generalización, alcanzando $90.27\,\%$ de exactitud, $90.26\,\%$ de *Macro F1* y ROC-AUC de $96.49\,\%$ en prueba independiente ($n = 5\,959$).

II. Metodología

Datos y preprocesamiento. Se utilizó la colección pública de reseñas de IMDb [3] en su subconjunto de 40 000 muestras (0 = negativa, 1 = positiva). La auditoría detectó 278 textos duplicados idénticos (205 negativos y 73 positivos) sin contradicciones. Al descartar copias redundantes, el conjunto consta de $N = 39\,722$ reseñas únicas balanceadas: 19 814 negativas ($49.88\,\%$) y 19 908 positivas ($50.12\,\%$, razón de desbalance 1.005).

El análisis exploratorio identificó que el $58.44\,\%$ de las reseñas contenía etiquetas HTML, el $86.93\,\%$ contracciones informales, el $9.35\,\%$ caracteres no ASCII y el $1.26\,\%$ apóstrofos tipográficos de Windows-1252. El pipeline determinista aplicó: (i) remoción de etiquetas HTML y URLs; (ii) normalización Unicode NFKD y decodificación ASCII; (iii) expansión de contracciones (p. ej., "*can't*" → "*cannot*", "*n't*" → "*not*"); y (iv) tokenización alfanumérica en minúsculas.

La longitud en palabras presenta una distribución asimétrica ($\mu = 229.2$, mediana 172, percentil $95 = 585$). Se fijó una longitud máxima de MAX_LEN $= 400$ tokens con truncado por la cola (*tail truncation*), preservando el cierre evaluativo donde los revisores sintetizan su veredicto. Para optimizar el cómputo, se implementó muestreo por cubetas (*BucketBatchSampler*, lote 256) con relleno dinámico mediante el token `<pad>`.

Partición y protocolo de evaluación. El conjunto depurado se dividió estratificadamente (semilla 42) en `Train` ($70\,\%$, 27 804), `Val` ($15\,\%$, 5 959) y `Test` ($15\,\%$, 5 959). El vocabulario (30 731 términos) se construyó **exclusivamente sobre `Train`** con frecuencia mínima ≥ 5 (reteniendo el $98.77\,\%$ de las ocurrencias y filtrando el ruido de baja frecuencia), definiendo los tokens `<pad>` (0) y `<unk>` (1). En `Test`, la cobertura léxica alcanzó el $98.47\,\%$ ($1.53\,\%$ de tasa OOV).

Se garantizó la total independencia de particiones: la comparación de cinco arquitecturas se realizó bajo dos semillas (42 y 123) por 15 épocas (detención temprana con paciencia 3) sobre un subconjunto estratificado del $25\,\%$ de `Train` (6 951) evaluado en `Val` (5 959). El modelo ganador se reentrenó sobre el $100\,\%$ de `Train` por 30 épocas (paciencia 4), manteniendo `Test` (5 959 reseñas) **estrictamente aislado** para una única evaluación final.

Representación vectorial y arquitectura recurrente. Se cargaron vectores GloVe 6B preentrenados [4] de dimensión $d = 100$ ($30\,731 \times 100$, cubriendo el $98.20\,\%$ del vocabulario y el $99.93\,\%$ de las ocurrencias en `Train`; con `<pad>`$= \mathbf{0}$ y `<unk>`$= \boldsymbol{\mu}_{\text{GloVe}}$). La red recurrente configurable comprende: (1) capa de *embedding* (congelada o con *fine-tuning*); (2) celda recurrente (RNN, GRU o LSTM, $H = 64$, 1 capa, unidireccional o bidireccional) con empaquetado dinámico (`pack_padded_sequence`) y `Dropout` de 0.3 en su entrada y salida; (3) agrupamiento temporal dual concatenado (*Concat Mean-Max Pooling*) [5], que computa en paralelo el promedio y el máximo sobre los estados ocultos descartando tokens de relleno: $h_{\text{pool}} = [h_{\text{mean}} \,\|\, h_{\text{max}}] \in \mathbb{R}^{2H}$ (128 dimensiones en unidireccional y 256 en bidireccional); y (4) clasificador lineal (128 o $256 \to 1$) que proyecta el vector agregado al logit de salida.

Función de pérdida, optimización y métricas. Se utilizó la entropía cruzada binaria con logits

TABLE I

COMPARACIÓN DE ARQUITECTURAS EN VAL ($n = 5\,959$, 15 ÉPOCAS, 2 SEMILLAS).

Arquitectura	Parám. Entr.	Val Loss	Acc (%)	F1-Score (%)	ROC-AUC (%)	Tiempo (s)
1. RNN simple (GloVe cong.)	10.7 k	0.608 ± 0.092	65.98 ± 10.58	71.66 ± 3.52	76.80 ± 5.13	12.6 ± 4.0
2. **GRU unidir. (GloVe cong.)**	**32.0 k**	$\mathbf{0.335 \pm 0.015}$	$\mathbf{86.22 \pm 0.76}$	$\mathbf{86.71 \pm 0.23}$	$\mathbf{93.61 \pm 0.08}$	$\mathbf{26.5 \pm 0.1}$
3. LSTM unidir. (GloVe cong.)	42.5 k	0.369 ± 0.007	84.53 ± 0.07	85.15 ± 0.29	92.27 ± 0.47	27.6 ± 0.0
4. BiLSTM (GloVe cong.)	84.7 k	0.339 ± 0.040	85.58 ± 1.22	85.68 ± 0.97	93.00 ± 1.63	33.0 ± 8.0
5. BiLSTM (GloVe fine-tuning)	3 157.8 k	0.387 ± 0.023	83.15 ± 1.26	83.76 ± 1.70	91.22 ± 1.65	94.2 ± 20.9

(`BCEWithLogitsLoss`):

$$\mathcal{L}(z, y) = \max(z, 0) - z \cdot y + \log\left(1 + e^{-|z|}\right) \qquad (1)$$

Esta formulación combina la sigmoide y la pérdida binaria en una sola expresión numéricamente estable con el truco *log-sum-exp*, previniendo gradientes nulos ante logits extremos y produciendo probabilidades calibradas $P(y = 1|x) = \sigma(z)$. Se aplicó `Adam` ($\eta = 0.002$ sin decaimiento ℓ_2 para no contraer los pesos recurrentes $\mathbf{W}_{hh}$ ni acentuar el desvanecimiento del gradiente; $\eta_{\text{base}} = 0.001$ y $\eta_{\text{embed}} = 0.0001$ en *fine-tuning*) con recorte de gradiente ($\|\nabla\|_2 \leq 1.0$). Se monitorizaron Exactitud (desempeño global en corpus balanceado), Precisión y Sensibilidad (control de falsos positivos y negativos por clase), *ROC-AUC* (capacidad discriminativa independiente del umbral) y *F1-Score*, métrica que rigió la selección del modelo para garantizar el equilibrio entre críticas negativas y positivas.

III. RESULTADOS

Comparación cuantitativa de arquitecturas (Validación). La Tabla I presenta los resultados multi-semilla (semillas 42 y 123, 15 épocas, paciencia 3) evaluados en `Val` ($n = 5\,959$). La RNN simple sufrió severo desvanecimiento de gradiente, colapsando en exactitud ($65.98 \pm 10.58\,\%$) con alta dispersión. Las celdas con compuertas superaron el $84\,\%$. La **GRU unidireccional** obtuvo el mejor balance general (*F1* de $86.71 \pm 0.23\,\%$, *ROC-AUC* de $93.61\,\%$), superando a LSTM ($85.15\,\%$) y BiLSTM ($85.68\,\%$), con menor tiempo de entrenamiento (26.5 s vs. 33.0 s).

Al habilitar el ajuste fino de *embeddings* en BiLSTM (`GloVe fine-tuning`), el rendimiento cayó a $83.76\,\%$ y el tiempo se triplicó (94.2 s), evidenciando sobreajuste al actualizar 3.16M de parámetros frente a los 84.7k del modelo congelado.

Desempeño final en prueba independiente. La arquitectura ganadora (GRU unidireccional con GloVe congelado) se reentrenó sobre el $100\,\%$ de `Train` (27 804 reseñas) por 30 épocas (paciencia 4), alcanzando su punto óptimo en la época 29 (`Val Loss`: 0.2677, `Val Acc`: $89.70\,\%$, `Val F1`: $89.89\,\%$).

Evaluada en `Test` ($n = 5\,959$, Tabla II), alcanzó **pérdida de** 0.2525, **exactitud de** $90.27\,\%$ ($5\,379/5\,959$) y ***Macro F1* de** $90.26\,\%$. La Fig. 1(a) detalla la matriz de confusión: la sensibilidad positiva fue de $92.47\,\%$ ($2\,762/2\,987$) y la negativa de $88.06\,\%$ ($2\,617/2\,972$). En la Fig. 1(b), la curva ROC exhibe un área de $96.49\,\%$ (*PR-AUC* de $96.39\,\%$). La exactitud fue consistente por longitud: $90.69\,\%$ (1–120 tokens), $90.26\,\%$ (121–180), $89.38\,\%$ (181–280), $89.93\,\%$ (281–400) y $91.54\,\%$ en secuencias truncadas > 400.

Análisis cualitativo e interpretabilidad. Las probabilidades en `Test` exhiben distribución bimodal (mediana > 0.99 en aciertos). Al evaluar la oclusión de tokens ($\Delta p_i = P_{\text{base}} - P_{\text{enmascarado}}$ con `<pad>`), adjetivos como "*terrible*" o "*masterpiece*" modulan fuertemente la predicción. En pruebas

TABLE II

MATRIZ DE CONFUSIÓN Y MÉTRICAS EN TEST ($n = 5\,959$).

Clase Real	Pred. Neg.	Pred. Pos.	Precisión (%)	Sensibilidad (%)	F1-Score (%)
Negativa (2 972)	**2 617**	355	92.08	88.06	90.02
Positiva (2 987)	225	**2 762**	88.61	92.47	90.50
Promedio Macro / Exactitud Global (5 379/5 959)			**90.35**	**90.26**	**90.26 / 90.27**

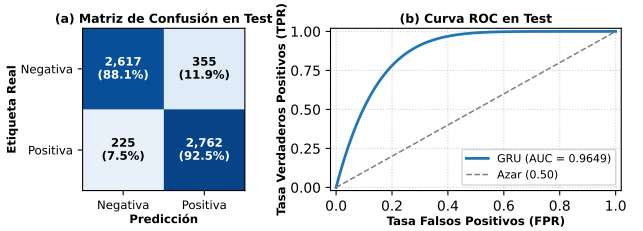


Fig. 1. Evaluación en `Test` ($n = 5\,959$): (a) Matriz de confusión; (b) Curva ROC (AUC = 0.9649) frente al azar.

de estrés lingüístico (6 críticas complejas), el modelo acertó 3 de 6: **Aciertos** $(3/6)$**:** resolvió la negación de adjetivos positivos ("*plot is not good...*", negativa con $P = 0.1485$, $\Delta p = -0.42$ por "*not*"), contrastes adversativos positivo $\rightarrow$ negativo ("*Great cast, but a terrible script...*", negativa con $P = 0.0372$, $\Delta p = -0.78$ por "*terrible*") y notas explícitas ("*9/10*", positiva con $P = 0.9989$). **Fronteras de error** $(3/6)$**:** falló en la atenuación por negación de adjetivo negativo ("*not bad at all...*", negativa con $P = 0.0698$, dominado por "*disaster*" y "*bad*"), el contraste negativo $\rightarrow$ positivo ("*slow and confusing, yet... masterpiece*", negativa con $P = 0.3436$) y el sarcasmo ("*Brilliant cure for insomnia...*", positiva con $P = 0.5625$, inducido por "*brilliant*").

IV. DISCUSIÓN

El desempeño responde a tres factores metodológicos: (i) **Parsimonia y regularización:** congelar GloVe (3.07M parámetros) limitó la optimización a solo 32 001 parámetros en GRU y clasificador (≈ 869 reseñas/parámetro), evitando el sobreajuste de BiLSTM con ajuste fino; (ii) **Compuertas y agregación dual:** la celda GRU mitigó el desvanecimiento del gradiente frente a la RNN simple ($65.98\,\%$, varianza $\pm 10.58\,\%$), mientras que *mean-max pooling* [5] preservó el contexto continuo y los picos enfáticos de opinión distribuidos en la secuencia; y (iii) **Calibración y dispersión de confianza:** en aciertos, el modelo exhibe alta confianza; no obstante, en los 580 errores de `Test`, las probabilidades se dispersaron en $[0.0002, 0.9995]$, demostrando que la red puede incurrir en sobreconfianza inducida por términos polarizados aislados en la rama de agrupamiento máximo (*Max Pooling*).

Contraste con trabajos relacionados. Con $90.27\,\%$ de exactitud en `Test`, la arquitectura supera la referencia de Maas *et al.* [3] ($88.89\,\%$) y la línea base convolucional de Kim [6] ($\approx 89.5\,\%$), con una fracción reducida de parámetros frente a modelos contextuales [5]. Aunque los *Transformers* reportan $> 93\,\%$, demandan órdenes de magnitud más cómputo.

Limitaciones y trabajo futuro. Las limitaciones radican en la naturaleza estática de GloVe [4], insensible al contexto local, y en la sensibilidad del agrupamiento máximo ante el sarcasmo. Como trabajo futuro se propone incorporar un mecanismo de atención temporal aprendible (*Self-Attention Pooling*) sobre la salida de la GRU y validar ensambles ligeros GRU-BiLSTM.

REFERENCES

[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho *et al.*, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proc. EMNLP*, 2014, pp. 1724–1734.

[3] A. L. Maas *et al.*, "Learning word vectors for sentiment analysis," in *Proc. 49th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2011, pp. 142–150.

[4] J. Pennington, R. Socher, and C. D. Manning, "GloVe: Global vectors for word representation," in *Proc. EMNLP*, 2014, pp. 1532–1543.

[5] J. Howard and S. Ruder, "Universal language model fine-tuning for text classification," in *Proc. 56th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2018, pp. 328–339.

[6] Y. Kim, "Convolutional neural networks for sentence classification," in *Proc. EMNLP*, 2014, pp. 1746–1751.